Огнева М. В.

Классификация

Метрические методы. Метод k-ближайших соседей

Метрические методы

Гипотеза непрерывности (для регрессии): близким объектам соответствуют близкие ответы.
Гипотеза компактности (для классификации): близкие объекты, как правило, лежат в одном классе.
Формализация понятия «близости»: задана функция расстояния $\rho : X \times X \to [0, \infty)$.
Пример. Евклидово расстояние и его обобщение: $\rho(x, x_i) = \left(\sum |x^j - x_i^j|^2\right)^{1/2}$,
$\rho(x, x_i) = \left(\sum w_j |x^j - x_i^j|^\rho\right)^{1/\rho}$
$x = (x^1, \ldots, x^n)$ — вектор признаков объекта x,
$x^i = (x_1^i, \ldots, x_n^i)$ — вектор признаков объекта x_i

Методы, использующие функции расстояния или метрики в пространстве объектов. Исходная идея их использования лежит в предположении, что в практических задачах часто встречаются зависимости, которые непрерывны. Но это понятие непрерывности скорее подходит для задач восстановления регрессии. А в задачах классификации аналогом непрерывности является так называемая гипотеза компактности — предположение о том, что близкие объекты, как правило, лежат в одном классе.

Что такое близость между объектами, как ее можно формализовать? Как правило, задается некая функция расстояния — это функция от пары объектов, которая паре ставит соответствие — неотрицательное число. Часто еще накладывают требование, чтобы это была метрика в пространстве объектов, то есть чтобы она была и симметричной, и выполнялось неравенство треугольника. Однако формально в методах нигде не используется предположение о том, что это метрика, поэтому, в общем-то, и функции расстояния, не являющиеся метриками нам тоже подходят.

Самым известным примером расстояния, наверное, является евклидово расстояние в признаковом пространстве. Объекты, как правило, у нас задаются n признаками. Если эти признаки числовые, то мы можем использовать евклидово расстояние. Можно эту конструкцию слегка обобщить, чтобы получить дополнительную гибкость в модели: например, ввести вместо двойки какую-то другую степень ρ или ввести веса признаков.

Однако есть масса задач, где изначально нет признаковых описаний объектов, и гораздо проще пользоваться не признаками, а непосредственно мерять расстояние между объектами. Примеры таких объектов — это символьные строки. Это могут быть тексты естественного языка, это могут быть нуклеотидные или аминокислотные последовательности, которые изучаются в биоинформатике. Чтобы сравнить текстовые строки, вообще говоря, произвольной длины, в таких задачах часто используется так называемое редакционное расстояние Левенштейна - это количество вставок и замен символов, которое необходимо произвести, чтобы привести одну строку в другую.

Другой, очень похожий пример, но уже между объектами еще более сложной природы: допустим, мы хотим сравнить 2 подписи, которые выполнены специальным электронным пером, которое запоминает координаты кончика пера ну и еще азимут движения пера. Значит, имеем 3 кривые, 3 временных ряда, и нам нужно сравнивать такие временные ряды. На картинке представлен пример такого сравнения, когда 2 похожие буквы сравниваются, и мы видим, что эти 3 кривые очень похожи с точностью до каких-то сжатий, растяжений, выравниваний. Можно придумать модель расстояния между такими траекториями, как модель пружинок, которые слегка сжимаются или растягиваются между маленькими локальными кусочками этих кривых, и посчитать энергию сжатий и растяжений пружинок - это и будет расстояние между этими объектами. Расстояние посчитать легко, а придумать здесь признаки было бы значительно сложнее.

Таким образом, расстояния бывают разные в прикладных задачах. Допустим, что кто-то нам уже дал функцию расстояния и теперь перед нами стоит задача — научиться классифицировать объекты.

KNN

Напоминание: для обучения классификатора необходимо иметь набор объектов, для которых заранее определены классы. Это множество называется обучающей выборкой.

Для классификации каждого из объектов тестовой выборки необходимо последовательно выполнить следующие операции:

1. Вычислить расстояние до каждого из объектов обучающей выборки;
2. Отобрать к объектов обучающей выборки, расстояние до которых минимально;
3. Класс классифицируемого объекта - это класс, наиболее часто встречающийся среди к ближайших соседей.

Взвешенный KNN

Веса можно определять как функцию от соседа или его номера: $w(x_i) = w(i)$. Или как функцию расстояния: $w(x(i)) = w((x, x_{(i)}))$

Объект x относится к тому классу, взвешенная сумма по объектам из множества k ближайших соседей для которого больше.

Для произвольного X отсортируем объекты $x_1, \ldots, x$:

$$\rho(, x^{(1)}) \quad \rho(, x^{(2)}) \quad \rho(, x^{()})$$

- $x_{(i)}^{()}$ — i-й сосед объекта среди $x_1, \ldots, x_l$;
- $y_{(i)}^{()}$ — ответ (класс) на i-м соседе объекта .
  Метрического алгоритма классификации:

$$(X) = \sum_{i=1}^{y} [y^{(i)} = y w(i,),$$

- $w(i,)$ — вес i-го соседа объекта , неотрицательный и не возрастающий по i;
- $_y()$ — оценка близости объекта к классу y.
  Преимущества:
- простота
- интерпретируемость
  Недостатки:
- неэффективное расходование памяти
- время выполнения
- неустойчивость к погрешностям
- отсутствие настраиваемых параметров (в исходном варианте)ё
  Проблемы:
- для двух классов оценки степени близости объекта к классу совпадают
- нигде не учитываем сами значения расстояний

Преимущества

Простота реализации: kNN очень просто реализуется (иногда говорят, что это «ленивое» обучение, потому что, собственно, никакого обучения здесь не происходит - мы просто запоминаем выборку, и потом классификация ближайших соседей заключается в поиске).

Интерпретируемость: метрические, классификации относятся алгоритмы также к методам рассуждения по прецедентам (case-based reasoning). Здесь действительно можно говорить о «рассуждении», так как на вопрос «почему объект и был отнесён к классу y?» алгоритм может дать понятное экспертам объяснение: «потому, что имеются схожие с ним прецеденты класса y», и предъявить список этих прецедентов.

Можно пытаться оптимизировать параметр - число соседей и выбрать его так, чтобы классификация была максимально надежной.

Недостатки

Приходится хранить обучающую выборку целиком. Это приводит к неэффективному расходу памяти и чрезмерному усложнению решающего правила. При наличии погрешностей (как в исходных данных, так и в модели сходства ρ) это может приводить к понижению точности классификации вблизи границы классов. Имеет смысл отбирать минимальное подмножество эталонных объектов, действительно необходимых для классификации.

Неустойчивость к погрешностям (выбросам). Чувствителен к разным масштабам и неинформативным признакам.

Поиск ближайшего соседа предполагает сравнение классифицируемого объекта со всеми объектами выборки за O(l) операций. Для задач с большими выборками или высокой частотой запросов это может оказаться накладно. Проблема решается с помощью эффективных алгоритмов поиска ближайших соседей, требующих в среднем O(l) операций.

В исходном виде модель алгоритмов kNN крайне бедна. Она имеет только свободный параметр , да и тот дискретный с небольшим числом разумных альтернатив. Для обогащения модели необходимо вводить веса объектов и/или параметризовать способ вычисления метрики.

Проблемы

Мы можем столкнуться с ситуацией, когда для двух классов оценки степени близости объекта к классу совпадают, и мы поэтому не понимаем, к какому из этих двух классов отнести наш объект. Для двух классов выходом является нечетное , для нескольких – ввод весов.

Мы нигде не учитываем сами значения расстояний. После того как мы провели ранжирование объектов обучения по возрастанию расстояний, у нас остались только порядковые номера этих объектов. Может возникнуть ситуация, когда например, идет классификация по пяти ближайшим соседям и четыре соседа находятся действительно близко от объекта, а пятый где-то совсем далеко. Конечно, в таком случае его надо было бы учесть с меньшим весом.

Настройка параметров

Параметры:

- число соседей
- веса соседей (соседи тестового примера могут входить с разными весами, например, чем дальше пример, тем с меньшим коэффициентом учитывается его "голос")

- метрики расстояния между объектами (часто используются метрика Хэмминга, евклидово расстояние, косинусное расстояние и расстояние Минковского). Отметим, что при использовании большинства метрик значения признаков надо масштабировать.
  Оптимизация параметра - число соседей.
  В общем, если мы берем слишком мало соседей, то среди них могут оказаться какие-то случайные шумовые выбросы. Если мы берем слишком много соседей, то мы построим слишком простой классификатор (который в любой точке пространства по сути будет выдавать одно и то же значение). И где-то посередине находится тот классификатор, который действительно будет прилично работать.
  LOO (leave-one-out) – метод скользящего контроля с исключением оценок по одному. Для каждого объекта проверяется, правильно ли он классифицируется по своим ближайшим соседям.

$$(, X^l) = \sum_{i=1}^{l} [(x_i \, X^l \{x_i\},) \neq y_i \to min$$

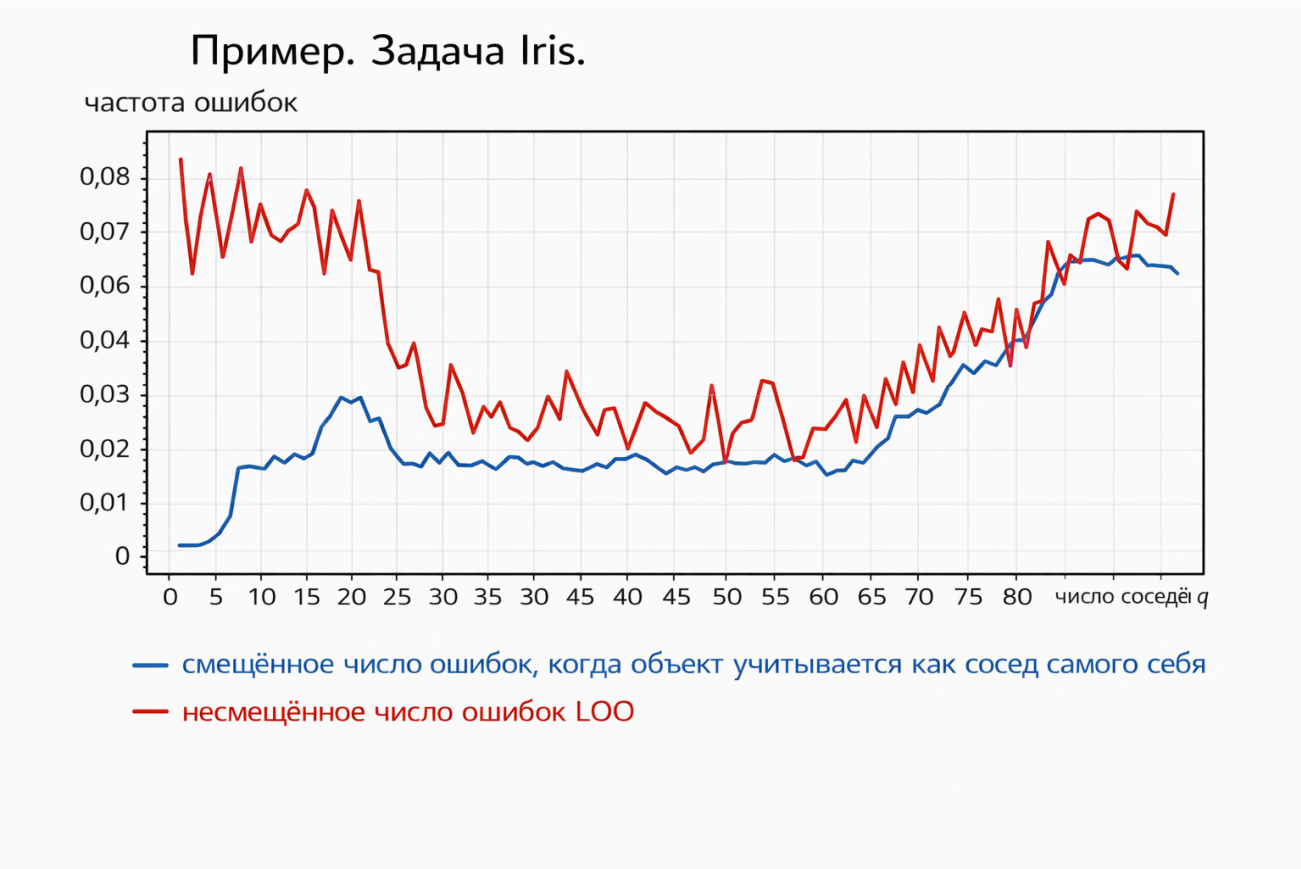

Если классифицируемый объект x не исключать из обучающей выборки, то ближайшим соседом x всегда будет сам x, и минимальное (нулевое) значение функционала LOO() достигаться при k = 1 (синяя кривая).
На красной кривой видно, что в данной задаче оптимально брать где-то от 30 до 60 соседей, а синяя кривая нам дает ложный ответ, что надо пользоваться методом первого ближайшего соседа.

Примечание

Iris - небольшой набор данных для задачи классификации, опубликованный еще в 1936 году Робертом Фишером (данные были собраны биологом Эдгаром Андерсоном).

Представлены по 50 описаний цветков одного из трех типов — Ирис щетинистый (Iris setosa), Ирис виргинский (Iris virginica) и Ирис разноцветный (Iris versicolor).

Для каждого цветка измерены четыре величины - длина чашелистника (англ. sepal length), ширина чашелистника (sepal width), длина лепестка (англ. petal length), ширина лепестка (англ. petal width).

Все цветки промаркированы одним из трех типов, что позволяет тестировать на нем алгоритмы классификации. Интересное наблюдение - один из классов цветков линейно отделим от двух других.

В общем зависимость от следующая: сначала качество на контроле становится все лучше с ростом , а затем качество начинает ухудшаться.
Выбирать следует такое значение , при котором достигается наилучшая оценка качества работы алгоритма на контроле.

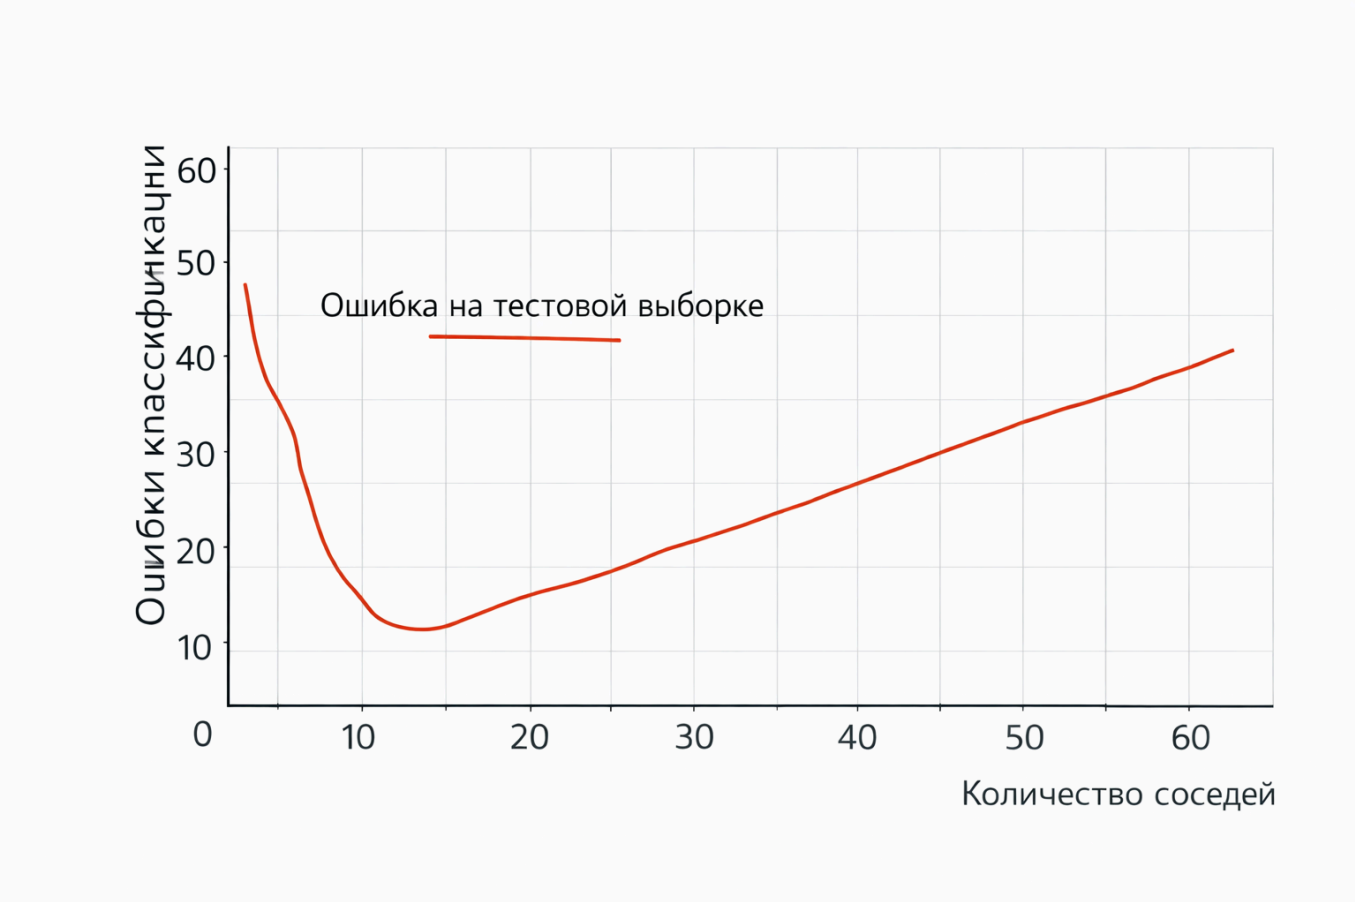

Выбор весов

– наш объект, i – номер соседа
$w(i,)$ – заданная весовая функция, которая оценивает степень важности i-го соседа для классификации объекта и. Естественно полагать, что эта функция не отрицательна и не возрастает по i (поскольку чем дальше объект, тем меньший вклад он должен вносить в пользу своего класса).

$$w(i,) = [i <= w_i,$$

где w_i – вес, зависящий только от номера соседа.
Возможные эвристики:
$w_i = \frac{+1-i}{}$ – линейное убывающие веса
$w_i = q^i$ – экспоненциально убывающие веса, $0 < q < 1$
Проблемы:

- как более обоснованно задать веса?
- возможно было бы лучше если бы вес $w(i,)$ зависел не от порядкового номера соседа i, а от расстояния до него
  $w() = \frac{1}{(+)}$
  $w() = q\,, 0 < q < 1$

Отбор эталонных объектов

Типичные представители классов - **эталоны**.
Ещё одна категория объектов - **неинформативные** или **периферийные**. Если их удалить из выборки, это практически не отразится на качестве классификации.
Наконец, в выборку может попасть некоторое количество **шумовых выбросов** - объектов, находящихся «в толще» чужого класса. Как правило, их удаление только улучшает качество классификации.
Идея: исключить из выборки шумовые и неинформативные объекты, оставив только минимальное достаточное количество эталонов.
Преимущества: повышается качество и устойчивость классификации, сокращается объём хранимых данных и уменьшается время классификации, затрачиваемое на поиск ближайших эталонов
Введем **функцию отступа**, которая позволит оценивать степень типичности объекта.

Понятие отступа

Рассмотрим классификатор $: X \to$ вида

$$() = \ {}_y \Gamma_y(), \ \ X$$

Отступом (margin) объекта $x_i \ \ X^l$ относительно классификатора $()$ называется величина

$$(x_i) = \Gamma_{y_i}(x_i) - {}_{yy_i} \Gamma_y(x_i)$$

Отступ показывает степень типичности объекта: чем больше (x_i), тем "глубже" x_i в своем классе
$(x_i) < 0 \equiv (x_i) \neq y_i$

Упорядоченные по возрастанию отступов объекты выборки, i
= 1,..., 200. Условное деление объектов на пять типов.
• Э - эталонные (можно оставить только их);
• Н - неинформативные (можно удалить из выборки);
• П - пограничные (их классификация неустойчива);
• О - ошибочные (причина ошибки - плохая модель);
• Ш - шумовые (причина ошибки - плохие данные).

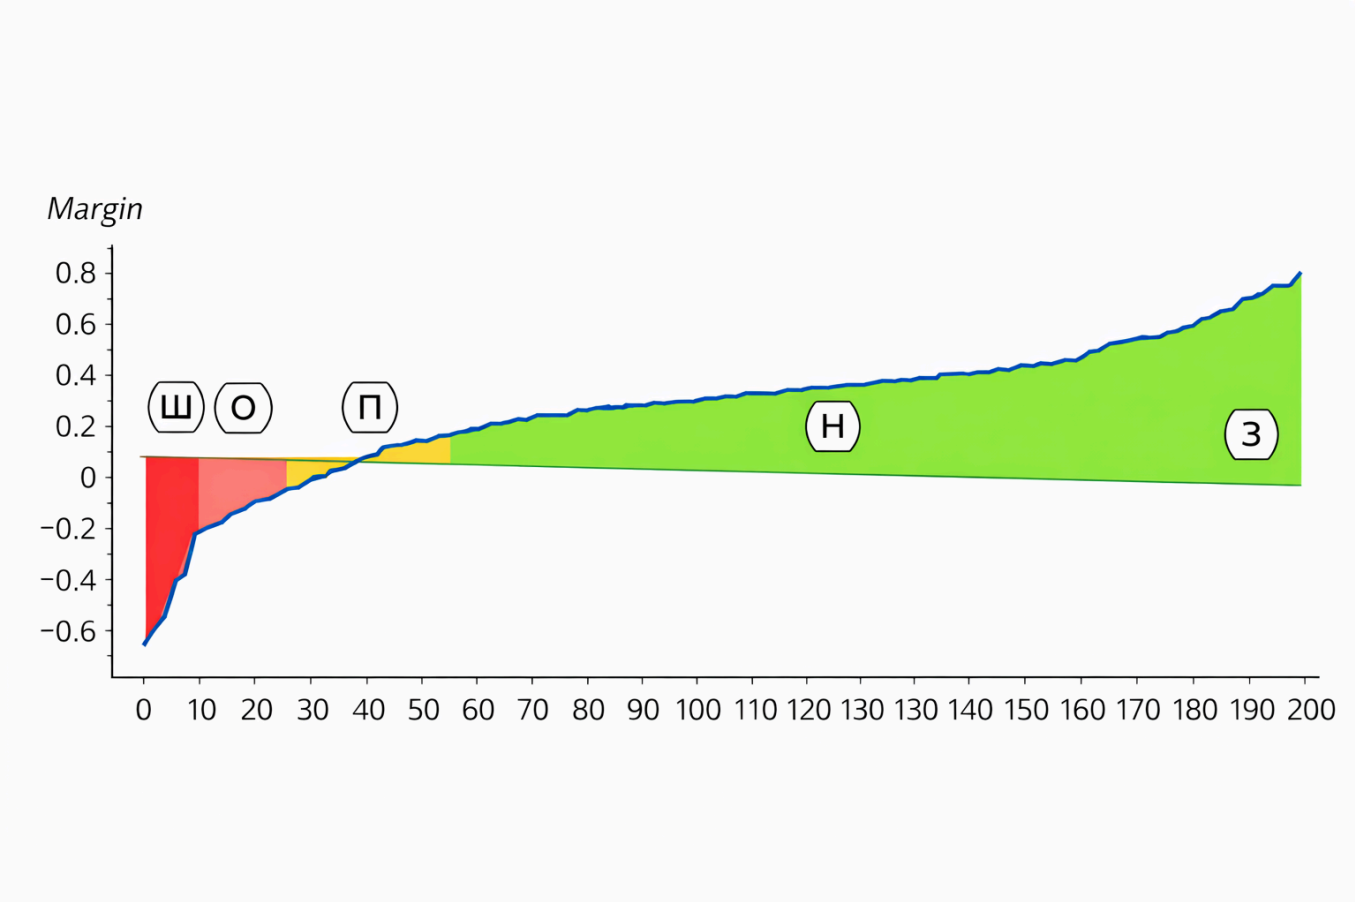

- Отступ показывает степень типичности объекта.
- Отступ отрицателен тогда и только тогда, когда алгоритм допускает ошибку на данном объекте.
- В зависимости от значений отступа обучающие объекты условно делятся на пять типов, в порядке убывания отступа.
  Эталонные объекты имеют большой положительный отступ, плотно окружены объектами своего класса и являются наиболее типичными его представителями.
  Неинформативные объекты также имеют положительный отступ. Изъятие этих объектов из выборки (при условии, что эталонные объекты остаются), не влияет на качество классификации. Фактически, они не добавляют к эталонам никакой новой

информации. Наличие неинформативных объектов характерно для выборок избыточно
большого объёма

Пограничные объекты имеют отступ, близкий к нулю. Классификация таких объектов неустойчива в том смысле, что малые изменения метрики или состава обучающей выборки могут изменять их классификацию.

Ошибочные объекты имеют отрицательные отступы и классифицируются неверно. Возможной причиной может быть неадекватность алгоритмической модели, в частности,
неудачная конструкция метрики р.

Шумовые объекты или **выбросы** - это небольшое число объектов с большими отрицательными отступами. Они плотно окружены объектами чужих классов и классифицируются неверно. Они могут возникать из-за грубых ошибок или пропусков в
исходных данных, а также по причине отсутствия важной информации, которая позволила бы отнести эти объекты к правильному классу.

Приведённая типизация условна. Не существует чёткого различия между «соседними» типами объектов. В частности, легко строятся примеры выборок, содержащих такие пары близких объектов, что любой из них может быть объявлен эталонным, а второй - неинформативным.
Шумовые и неинформативные целесообразно удалять из выборки.
Распределение значений отступов в выборке даёт полезную дополнительную информацию не только об отдельных объектах, но и о выборке в целом.
Если основная масса объектов имеет положительные отступы, то разделение выборки можно считать успешным. Если в выборке слишком много отрицательных отступов, то гипотеза компактности не выполняется, и в данной задаче при выбранной метрике применять алгоритмы типа kNN нецелесообразно. Если значения отступов концентрируются вблизи нуля, то ждать надёжной классификации не приходится, так как слишком много объектов оказываются в пограничной «зоне неуверенности»

Алгоритм STOLP

Задача: выбрать оптимальное подмножество эталонов X^l
Классификатор будет иметь вид:

$$(\,) = \sum_{y} \sum_{x_i} [y^{(i)} = y w(i,\,)$$

$x^{(i)}$ – i-й сосед объекта среди
$y^{(i)}$ – ответ на i-м соседе объекта ;
$w(i,\,)$ – произвольная функция веса i-го соседа
Алгоритм STOLP:

- исключить выбросы и, возможно, пограничные объекты
- найти по одному эталону в каждом классе
- добавлять эталоны, пока есть отрицательные отступы

Алгоритм STOLP для отбора эталонных объектов

Вход: X^l параметры , l_0
Выход: Множество опорных объектов X^l;

---

1. **для всех** x_i X^l проверить, является ли x_i выбросом:
2. **если** $(x_i, X^l) <$, то
3. $X^{l-1} := X^l \{x_i\}$ $l := l - 1$
4. Инициализация: взять по одному эталону от каждого класса:
   $:= \{ {}_{x_i X^l_y} (x_i, X^l) | y \ \}$
5. **пока** $\neq X^l$
6. Выделить множество объектов с ошибкой $(\ )$:
   $:= \{x_i \ X^l : (x_i,) < 0\}$
7. **если** $|| < l_0$ **то выход**;
8. Присоединить к объект с наименьшим отступом:
   $x_j := {}_x (x,) := \{x_j\}$

X^l – обучающая выборка; - порог фильтрации выбросов; l_0 - допустимая доля ошибок.
Идея отбора эталонов реализована в алгоритме STOLP. Мы рассмотрим его обобщённый вариант с произвольной весовой функцией $w(i,)$. Будем строить метрический алгоритм $(\ )$ вида (3.1), где X^l – множество эталонов.
Обозначим через $(x_i,)$ отступ объекта x_i относительно алгоритма $(x_i\ )$. Большой отрицательный отступ свидетельствует о том, что объект x_i окружен объектами чужих классов, следовательно, является выбросом. Большой положительный отступ означает, что объект окружён объектами своего класса, то есть является либо эталонным, либо периферийным.
Алгоритм начинает с отсева выбросов (шаги 1-3). Из выборки X^l исключаются все объекты x_i с отступом (x_i, X^l), меньшим заданного порога . Если взять $= 0$, то оставшиеся объекты будут классифицированы верно. Вместо можно задавать долю исключаемых объектов с наименьшими значениями отступа.
Затем формируется начальное приближение – в заносится по одному наиболее типичному представителю от каждого класса (шаг 4).
После этого начинается процесс последовательного «жадного» наращивания множества . На каждом шаге к присоединяется объект x_i , имеющий минимальное значение отступа. Так продолжается до тех пор, пока число ошибок не окажется меньше заданного порога l_0

. Если положить $l_0 = 0$, то будет построен алгоритм $(\ )$, не допускающий ошибок на обучающих объектах, за исключением заранее исключённых выбросов.
В результате каждый класс будет представлен в одним «центральным» эталонным объектом и массой «приграничных» эталонных объектов, на которых отступ принимал наименьшие значения в процессе итераций. Параметр позволяет регулировать ширину зазора между эталонами разных классов. Чем больше , тем дальше от границы классов будут располагаться «приграничные» эталоны, и тем более простой, менее «изрезанной» будет граница между.

Преимущества отбора эталонов:

- сокращается число хранимых объектов
- сокращается время классификации
- объекты распределяются по величине отступов

  Недостатки алгоритма STOLP:
- необходимость задавать параметр
- относительно низкая эффективность $(||^2 l)$

  Другие методы отбора:
- стратегия последовательного удаления не-эталонов
- минимизация полного скользящего контроля (CCV)
- FRiS-STOLP на основе оценок конкурентного сходства

В описанном варианте алгоритм STOLP имеет относительно низкую эффективность. Для присоединения очередного эталона необходимо перебрать множество объектов X^l, и для каждого вычислить отступ относительно множества эталонов . Общее число операций составляет $(||^2 l)$. Для ускорения алгоритма можно добавлять сразу по несколько эталонов, не пересчитывая отступов. Если при этом выбирать добавляемые эталоны достаточно далеко друг от друга, то добавление одного из них практически не будет влиять на отступы остальных. Аналогично, на этапе отсева выбросов можно вычислить отступы только один раз, и потом отбросить все объекты с отступами ниже . Реализация этих идей не показана в Алгоритме, чтобы не загромождать его техническими подробностями.
Результатом работы алгоритма STOLP является разбиение обучающих объектов на три категории: шумовые, эталонные и неинформативные. Если гипотеза компактности верна и выборка достаточно велика, то основная масса обучающих объектов окажется неинформативной и будет отброшена. Фактически, этот алгорит выполняет сжатие исходных данных.

Д/з:

Продукт	Сладость	Жесткость	Класс
Яблоко	10	9	Фрукт
Банан	10	1	Фрукт
Морковь	7	10	Овощ
Петрушка	3	8	Овощ
Апельсин	7	3	Фрукт
Груша	9	7	Фрукт
Огурец	2	8	Овощ
Капуста	1	9	Овощ
Баклажан	3	7	?
Помидор	6	3	?

1. (опционально нарисовать, но не обязательно). Подумать какой ввести третий признак и посчитать (еще объектов можно добавить), чтобы получить адекватный результат
2. Постройте набор точек на плоскости, которые представляют два класса ($n \leq 10$), где каждая точка будет неправильно классифицирована соответствии с ее ближайшим соседом.