# Возможные критерии останова

Если какая-то вершина не была поделена, а была объявлена листом, нужно определить прогноз, который будет содержаться в данном листе. В этот лист попала некоторая подвыборка $X$ исходной обучающей выборки и требуется выбрать такой прогноз, который будет оптимален для данной подвыборки.
Регрессия:

$$a_m = \frac{1}{|X_m|} \sum_{i \in X_m} y_i$$

Классификация:

$$a_m = \arg\max_{y \in Y} \sum_{i \in X_m} [y_i = y]$$

Вероятности классов:

$$a_{mk} = \frac{1}{|X_m|} \sum_{i \in X_m} [y_i = k]$$

# Критерии информативности (для выбра оптимального разбиения)

Критерий ошибки:

$$Q(X_m, j, t) = \frac{|X_t|}{|X_m|} H(X_t) + \frac{|X_r|}{|X_m|} H(X_r)$$

где $\frac{|X_t|}{|X_m|} H(X_t)$ – разброс ответов в левом листе, $\frac{|X_t|}{|X_m|} H(X_t)$ и $\frac{|X_r|}{|X_m|} H(X_r)$ – доля объектов в листьях.
Функция $H(X)$ называется **критерием информативности**: ее значение должно быть тем меньше, чем меньше разброс ответов.
В случае регрессии разброс ответов – это дисперсия, поэтому критерий информативности в задачах регрессии записывается следующим образом:

$$\bar{y}(X) = \frac{1}{|X|} \sum_{i \in X} y_i$$

$$H(X) = \frac{1}{|H|} \sum_{i \in X} (y_i - \bar{y}(X))^2$$

Сформулировать критерий информативности для задачи классификации несколько сложнее

Пусть $p_k$ – доля объектов класса $k$ в выборке $X$:

$$p_k = \frac{1}{|X|} \sum_{i \in X} [y_i = k]$$

Тогда **критерий** информативности **Джини** формулируется в терминах $p_k$ следующим образом:

$$H(X) = \sum_{k=1}^{K} p_k (1 - p_k)$$

Если $p_1 = 1, p_2 = \dots = p_k = 0$, то $H(X) = 0$. Оптимум достигается, когда все ответы относятся к одному классу.

# Энтропийный критерий информативности

$H(X) = -\sum_{k=1}^{K} p_k \ln p_k$
Считаем, что $0 \ln 0 = 0$.
Если $p_1 = 1, p_2 = \dots = p_k = 0$, то $H(X) = 0$
**Замечание**. Энтропийный критерий имеет интересный физический смысл. Он заключается в том, что показывает, насколько распределение классов в $X$ отличается от вырожденного. Энтропия в случае вырожденного распределения равна 0: такое распределение характеризуется минимальной возможной степенью неожиданности. Напротив, равномерное распределение самое неожиданное, и ему соответствует максимальная энтропия.

Критерий ошибки измеряет разброс ответов после разбиения. Выражается через критерий информативности. В регрессии: MSE. В классификации: критерий Джини и энтропийный критерий.

## Пример

Задача о предсказании результатов матча (соперник выше в турнирной таблице, играем дома, участвуют ли в матче лидеры команды, идет ли дождь во время матча)

| № матча | Выше? (V) | Дома? (D) | Лидеры? (L) | Дождь? (R) | Победа (Y) |
|---|---|---|---|---|---|
| 1 | 1 | 1 | 1 | 1 | 0 |
| 2 | 1 | 1 | 1 | 0 | 1 |
| 3 | 1 | 1 | 0 | 0 | 0 |
| 4 | 0 | 1 | 0 | 0 | 1 |
| 5 | 0 | 0 | 0 | 0 | 0 |
| 6 | 0 | 1 | 0 | 1 | 1 |

| № матча | Выше? (V) | Дома? (D) | Лидеры? (L) | Дождь? (R) | Победа (Y) |
|---|---|---|---|---|---|
| 7 | 1 | 0 | 1 | 1 | 0 |

$Pr(V = 0) = 3/7$
$Pr(V = 1) = 4/7$
$Pr(Y = 0 \mid V = 0) = 1/3$
$Pr(Y = 1 \mid V = 0) = 2/3$
$Pr(Y = 0 \mid V = 1) = 3/4$
$Pr(Y = 1 \mid V = 1) = 1/4$
$Gini(V) = 3/7 * 1/3 * 2/3 + 4/7 * 3/4 * 1/4 = 0.21$

$Pr(D = 1) = 5/7$
$Pr(D = 0) = 2/7$
$P(Y = 0 \mid D = 1) = 2/5$
$P(Y = 1 \mid D = 1) = 3/5$
$P(Y = 0 \mid D = 0) = 1$
$P(Y = 1 \mid D = 0) = 0$
$Gini(D) = 5/7 * 2/5 * 3/5 = 0.171$

$Pr(L = 0) = 4/7$
$Pr(L = 1) = 3/7$
$Pr(Y = 0 \mid L = 0) = 2/4$
$Pr(Y = 1 \mid L = 0) = 2/4$
$Pr(Y = 0 \mid L = 1) = 2/3$
$Pr(Y = 1 \mid L = 1) = 1/3$
$Gini(L) = 4/7 * 2/4 * 2/4 + 3/7 * 2/3 * 1/3 = 0.24$

$Pr(R = 0) = 4/7$
$Pr(R = 1) = 3/7$
$Pr(Y = 0|R = 0) = 2/4 = 1/2$
$Pr(Y = 1|R = 0) = 2/4 = 1/2$
$Pr(Y = 0|R = 1) = 2/3$
$Pr(Y = 1|R = 1) = 1/3$
$Gini(R) = 4/7 * (1/2 * 1/2) + 3/7 * (2/3 * 1/3) = 1/7 + 2/21 = 0.24$

Находим признак с минимальным Джини – D. Этот признак идет в вершину дерева. Тренировочная выборка разбивается на две части. После работаем только с левой вершиной (там где D = 1).

| № матча | Выше? (V) | Лидеры? (L) | Дождь? (R) | Победа (Y) |
|---|---|---|---|---|
| 1 | 1 | 1 | 1 | 0 |
| 2 | 1 | 1 | 0 | 1 |
| 3 | 1 | 0 | 0 | 0 |
| 4 | 0 | 0 | 0 | 1 |
| 6 | 0 | 0 | 1 | 1 |

$Gini(V) = 2/5 * 0/2 * 2/2 + 3/5 * 2/3 * 1/3 = 0.13$
$Gini(L) = 0.23$
$Gini(R) - 0.23$

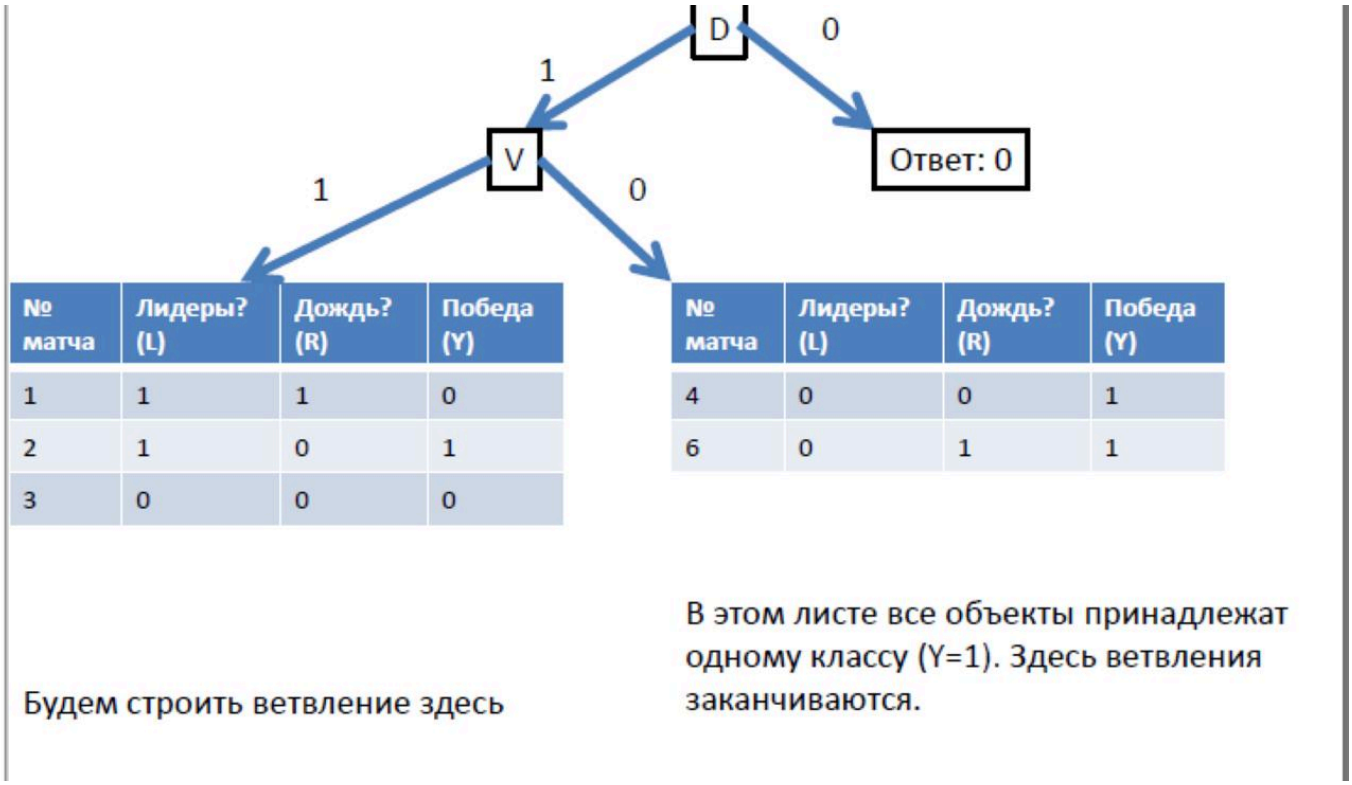


Выбираем для ветвления признак $V$. Разбиваем опять на две части выборку. После работаем только с левой вершиной (там где V = 1).

| № матча | Лидеры? (L) | Дождь? (R) | Победа (Y) |
|---|---|---|---|
| 1 | 1 | 1 | 0 |
| 2 | 1 | 0 | 1 |
| 3 | 0 | 0 | 0 |

$Gini(L) = 0.16$
$Gini(R) = 0.16$

Можно выбрать любой из признаков.

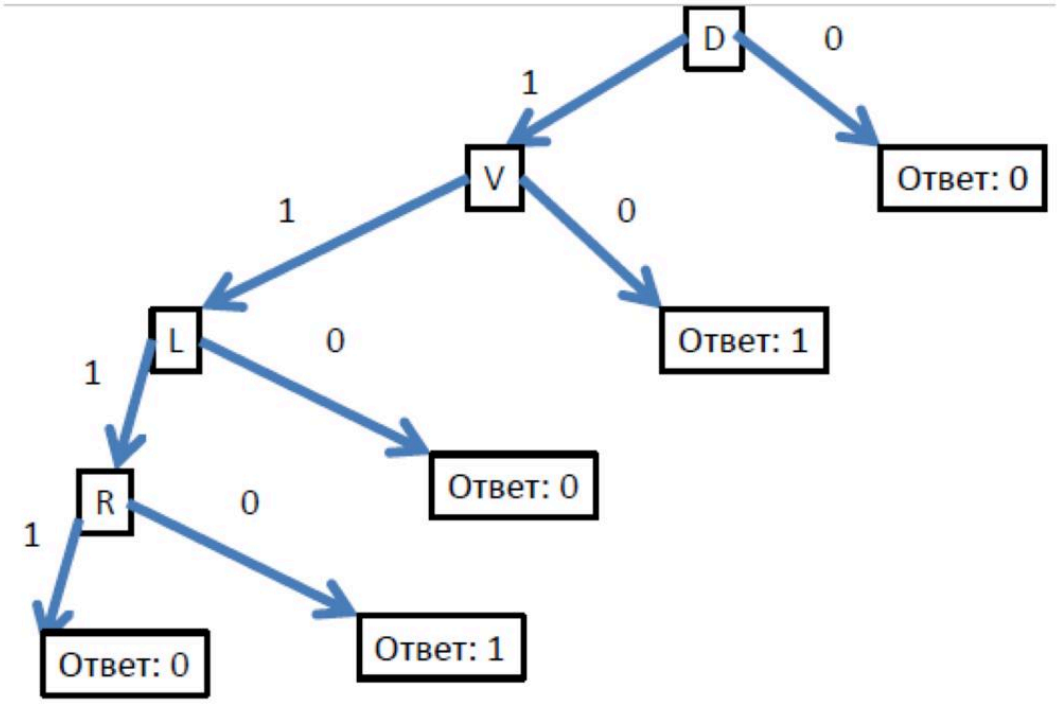


## Повторяющиеся признаки

Пример дерева, позволяющего оценить вероятность кифоза после операции на позвоночнике с учетом возраста пациента и позвонка, на котором была начата операция.

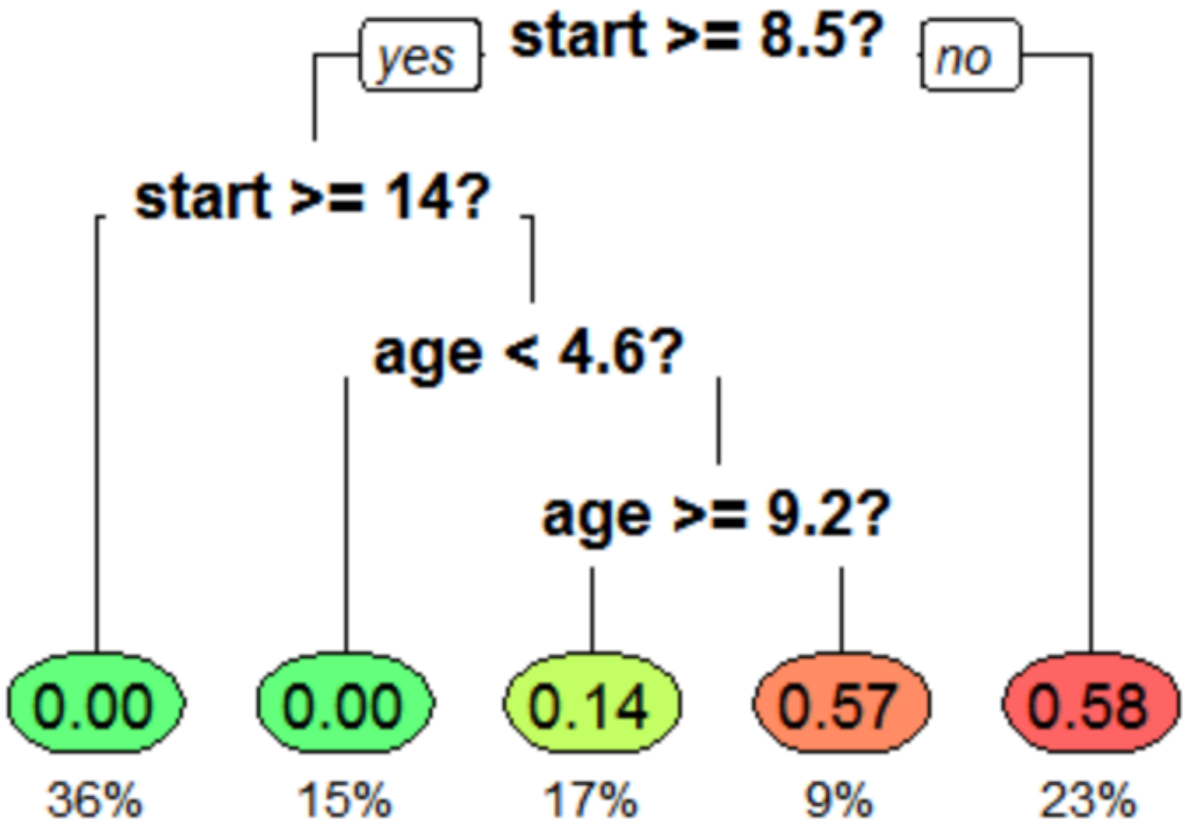


## Борьба с переобучением: критерий останова и стрижка деревьев

**Критерий останова** используется, чтобы принять решение: р**азбивать вершину дальше или сделать листовой**.
Худший случай решающего дерева – такое, в котором каждый лист соответствует своему объекту обучающей выборки. В этом случае дерево будет максимально переобученным и не будет обобщать информацию, полученную из обучающей выборки.
Самый простой критерий останова проверяет, все ли объекты в вершине относятся к одному классу. Однако такой критерий останова может быть использован только в случае простых выборок, так как для сложных он остановится только тогда, когда в каждом листе останется примерно по одному объекту.
Гораздо более устойчивый и полезный критерий проверяет, сколько объектов оказалось в вершине, и разбиение продолжается, если это число больше, чем некоторое выбранное $n$. Соответственно, если в вершину попало $\leq n$ объектов, она становится листовой.
Параметр $n$ нужно подбирать. При этом выбирать п нужно так, чтобы по $n$ объектам, которые попали в вершину, можно было устойчиво построить прогноз.
Случай $n = 1$ является худшим случаем, описаным выше. Существует рекомендация, что $n$ нужно брать равным 5.

Еще один критерий, гораздо более грубый, заключается в **ограничении на глубину дерева**. Этот критерий хорошо себя зарекомендовал при построении композиций, когда много решающих деревьев объединяют в один сложный алгоритм.
Другой подход к борьбе с переобучением деревьев – **стрижка**.
Он заключается в том, что сначала строится решающее дерево максимальной сложности и глубины, до тех пор, пока в каждой вершине не окажется по 1 объекту обучающей выборки. После этого начинается «стрижка», то есть удаление листьев в этом дереве по определенному критерию.
Например, можно стричь до тех пор, **пока улучшается качество некоторой отложенной выборки**.
Существует мнение, и это подкреплено многими экспериментами, что стрижка работает гораздо лучше, чем простые критерии, о которых говорилось раньше. Но стрижка очень ресурсоёмкая процедура, так как, например, может потребоваться вычисление качества дерева на некоторой валидационной выборке на каждом шаге.
На самом деле, сами по себе деревья на сегодняшний день почти не используются, они бывают нужны только для построения композиции и объединения большого числа деревьев в один алгоритм. В случае с композициями такие сложные подходы к борьбе с переобучением уже не нужны, так как достаточно простых критериев останова, ограничения на глубину дерева или на число объектов в листе.

# Работа с категориальными признаками

Условие $x^j < t$ можно записывать только для вещественных или бинарных признаков.
Для категориальных признаков можно строить $n$-арные деревья, то есть такие деревья, что из каждой вершины могут выходить до $n$ ребер.
Если $x^j$ – категориальный признак, который может принимать значения $\{c_1, \ldots, c_n\}$, то можно разбить вершину на $n$ вершин таким образом, что в $i$-ую дочернюю вершину дут объекты с $x^j = c_i$.
Критерий ошибки такого разбиения строится по аналогии со случаем бинарного дерева. Поскольку $X_m$ разбивается на $n$ частей, а не на две, в выражении будет $n$ слагаемых:

$$Q(X_m, j) = \sum_{i=1}^{n} \frac{|X_i|}{|X_m|} H(X_i) \to \min_j$$

Таким образом, если вершину $m$ нужно разбить, рассматриваются все возможные вещественные, бинарные и категориальные признаки. Для вещественных и бинарных признаков считается $Q(X_m, j, t)$, а для $n$-арных - $Q(X_m, j)$.
Разбиение вершины будет происходить по тому признаку, для которого значение критерия ошибки будет минимальным.
**Замечание**. При делении вершины по категориальному признаку получается больше дочерних вершин, на которых, очень вероятно, будет достигаться более высокое качество и более низкое значение критерия информативности, поэтому, скорее всего, при таком

подходе предпочтение почти всегда будет отдаваться разбиению по категориальным признакам с большим числом возможных значений. В результате получается много листьев в дереве, что почти гарантированно может привести к переобучению.
Однако это не всегда так. Если выборки настолько большие, что даже после разбиения по категориальному признаку в каждом поддереве будет оставаться много объектов, то такое дерево будет неплохо работать, поскольку оно будет восстанавливать сложные зависимости, и при этом не переобучаться при использовании должного критерия останова.

# Бинарные деревья с разбиением множества значений

Пусть $x^j$ – категориальный признак, который может принимать значения $\{c_1, \ldots, c_n\}$ и нужно разбить вершину $m$.
Для этого сначала необходимо разбить множество значений категориального признака на два не пересекающихся подмножества:
$C = C_1 \cup C_2, C_1 \cap C_2 = \emptyset$
После того, как такое разбиение построено, условие в данной вершине будет выглядеть следующим образом: $[x^j \in C]$.
Как разбивать?

## Как разбивать?

Отсортируем значения
Заменим $c_{(1)}, \ldots, c_{(n)}$ на $1, \ldots, n$
Будем работать как с вещественным признаком
Сортировка значений для бинарной классификации производится по следующему принципу:

$$\frac{\sum_{i \in X_m}[x_i^j = c_{(1)}][y_i = +1]}{\sum_{i \in X_m}[x_i^j = c_{(1)}]} \leq \cdots \leq \frac{\sum_{i \in X_m}[x_i^j = c_{(n)}][y_i = +1]}{\sum_{i \in X_m}[x_i^j = c_{(n)}]}$$

Фактически, значения категориального признака сортируются по возрастанию доли объектов класса +1 среди объектов выборки $X_m$ с соответствующим значением этого признака.
Для регрессии аналогично, но вычисляется не доля объектов положительного класса, а средний ответ по всем объектам, у которых значение категориального признака равно $c$:

$$\frac{\sum_{i \in X_m}[x_i^j = c_{(1)}]y_i}{\sum_{i \in X_m}[x_i^j = c_{(1)}]} \leq \cdots \leq \frac{\sum_{i \in X_m}[x_i^j = c_{(n)}]y_i}{\sum_{i \in X_m}[x_i^j = c_{(n)}]}$$

## Бинарные деревья

Главная особенность такого подхода состоит в том, что полученный результат полностью эквивалентен результату, который можно было бы получить в результате полного перебора.
Это условие работает для критерия Джини, MSE и энтропийного критерия.

# Дополнительные материалы

1. Выбор порога – https://habr.com/ru/articles/171759/, https://habr.com/ru/articles/270449/, https://habr.com/ru/companies/ods/articles/322534/

# Д/з

1. Как работают следующие методы построения деревьев: ID3, C4.5, CART?
2. Разобрать библиотечные методы для построения деревьев и их параметры.