Важность признаков (Feature Importance)

Интерпретируемость модели (продолжение)

В приложениях, где **цена ошибки высока** (например, в задаче медицинской диагностики, определяющей, нужно ли пациенту делать операцию), **важна не только точность, но и способность модели обосновать своё решение** (для врача). Поэтому в таких приложениях лучше использовать несколько интерпретируемых моделей, а не одну сложную. Модель, способная объяснить свои прогнозы, вызывает больше доверия и проще внедряется на практике.
Интерпретируемость позволяет **оценить адекватность принятого решения**: было ли оно принято, **основываясь на сильных и значимых факторах** (causal factors), или **модель переобучилась и приняла пусть даже верное решение, но отталкиваясь от ложных взаимосвязей** (false correlations).
Например, в задаче классификации кошек и собак на изображении можно проанализировать факторы, которые повлияли на тот или иной прогноз. Это могут быть характерные факторы, такие как размер и расположение (кошки могут забираться на деревья, а собаки - нет). Или это могут быть ошибочные факторы (например, наличие снега на заднем плане), которые в силу ограниченности обучающей выборки присутствовали в комбинации только с одним из классов, но не с другим (например, со снегом попадались только фото с собаками).
Оценка адекватности модели **позволяет производить отладку** модели, делая её прогнозы более логичными и корректными.
В процессе интерпретации прогнозов модели иногда можно отследить, что модель использует какие-либо запрещённые факторы (связанные с человеческими предубеждениями, дискриминаций и т.д.) или модель может опираться на какие-то приватные признаки о пользователях, использование которых не разрешено законом.
Методы интерпретации делятся на

- привязанные к конкретной модели, такой как решающее дерево, линейная регрессия и т.д (model based);
- не зависящие от модели (model agnostic).

Модель является **глобально интерпретируемой**, если человек понимает весь процесс принятия решений целиком для любых объектов.
Локальная интерпретируемость означает, что человек может понять, почему для конкретного объекта было принято то или иное решение.
Простые модели (white-box models), как правило, не могут обеспечить наилучшую

точность, зато обладают глобальной интерпретируемостью. Примерами таких моделей являются:

- метрические методы (при использовании небольшого числа локальных объектов);
- линейные модели (в целом не являются интерпретируемыми) регрессии и классификации (от небольшого числа признаков);
- решающие деревья небольшой глубины;
- метод наивного Байеса (naive Bayes).

При решении ответственных задач с высокой ценой ошибки (например, при предсказании, нужно ли делать пациенту операцию или нет) именно таким моделям отдаётся предпочтение, в силу их интерпретируемости.
Сложные модели (black-box models) способны моделировать более широкий класс зависимостей, поэтому, при достаточном объёме обучающих данных, обеспечивают более точные прогнозы. Но из-за сложности внутренней логики их непосредственная интерпретация затруднена. Однако существуют опосредованные способы анализа прогнозов и для сложных моделей.
Замечание. Очень часто важность признаков рассматривают в контексте с отбором признаков. Однако, не всегда эта одна и та же задача. Исследование важности не всегда повлечет за собой отбор. Как мы уже видели, это может быть связано с проблемой интерпретируемости модели, с обнаружением проблем в данных и т.д.

Классификация методов оценки важности признаков

Все методы можно разделить на три группы:

- **встроенные** (присущи конкретному алгоритму),
- **модельно-зависимые** (анализ коэффициентов)
- **модельно-независимые** (универсальные).

Встроенные методы (на основе структуры модели)

Некоторые алгоритмы сами вычисляют важность признаков в процессе обучения.
Для моделей на основе деревьев (Random Forest, XGBoost, LightGBM, CatBoost):

- алгоритм считает, насколько часто признак используется для разбиения данных в узлах деревьев и как сильно это разбиение уменьшает неопределенность (например, энтропию или Gini Impurity).
- чем ближе значение к вершине дерева и чем больше веток оно расщепило, тем оно важнее. В некоторых библиотеках это считается автоматически (атрибут feature_importances).

Модельно-зависимые методы (на основе коэффициентов)

Для линейных моделей (Linear Regression, Logistic Regression, SVM с линейным ядром):

- анализ весов (коэффициентов) модели.
- чтобы сравнить коэффициенты между собой, данные обязательно должны быть нормализованы (масштабированы). Если признаки измеряются в разных единицах (рубли и метры), большой коэффициент не всегда означает большую важность.
- чем больше абсолютное значение веса, тем сильнее признак влияет на целевую переменную (для стандартизированных данных).

Модельно-независимые методы (универсальные)

Эти методы работают для любой модели, так как они смотрят только вход и на выход модели, не залезая в ее "голову".

Permutation Feature Importance (Важность на основе перестановок)

Обучается модель и замеряется её качество (например, точность) на тестовых данных.
Берется один признак, и его значения случайным образом перемешиваются (permutation), разрушая связь между признаком и целевой переменной.
Модель снова делает предсказания на "испорченных" данных.
Важность = (Исходное качество - Качество с перемешанным признаком).
Итог. Если после перемешивания признака качество упало сильно – признак был важен. Если не изменилось - признак бесполезен.

Основные алгоритмы Sklearn для определения важности признаков

Tree-based feature importance – встроенный метод для деревьев решений и ансамблей на их основе (RandomForestClassifier, RandomForestRegressor, ExtraTreesClassifier, ExtraTreesRegressor, GradientBoostingClassifier, GradientBoostingRegressor)
Permutation importance – универсальный метод, работающий с любыми моделями через модуль sklearn.inspection
Linear models coefficients – использование коэффициентов линейных моделей (LinearRegression, LogisticRegression, Ridge, Lasso)

Отбор признаков:
SelectFromModel – автоматический отбор признаков на основе их важности

Recursive Feature Elimination (RFE) — итеративное удаление признаков с оценкой влияния на модель

Метод	Принцип работы	Вычислительная сложность	Стабильность
feature importance	Impurity-based	Низкая $O(n)$	Средняя
permutation_importance()	Permutation-based	Высокая $O(n^2)$	Высокая
SelectFromModel	Threshold-based	Зависит от базовой модели	Зависит от базы
RFE	Iterative elimination	Очень высокая $O(n)$	Высокая

SHAP (SHapley Additive exPlanations):

Основан на теории игр и теории кооперативных игр Шепли. Он рассматривает каждый признак как "игрока" , который вносит вклад в итоговый "выигрыш" (предсказание). Вычисляет вклад каждого признака для каждого отдельного предсказания. Усреднив эти вклады по всем объектам, мы получаем глобальную важность признаков.
Есть мнение, что это самый надежный и интерпретируемый метод на сегодня. Он показывает не только что важно, но и как признак влияет на прогноз (положительно или отрицательно).

Идея

Рассмотрим следующий сценарий: группа людей играет в игру. По итогам игры они получают определенное вознаграждение. Как игроки могут разделить это вознаграждение между собой таким образом, чтобы полученное вознаграждение отражало вклад каждого игрока?
Есть несколько пунктов, с которыми каждый игрок может согласиться. Выполнение следующих условий будет означать, что игра «честна» в соответствии со значениями Шепли:

- Сумма индивидуальных вознаграждений должна равняться общему вознаграждению.
- Если два человека внесли одинаковый вклад, то они должны получить одну и ту же сумму вознаграждения.
- Тот, кто не привнес никакого вклада, ничего не получит.
- Если группа играет в две игры, то награда человека от обеих игр должна быть равна вознаграждению за первую игру плюс вознаграждение за вторую игру.

$$[\phi_i(f) = \sum_{S \subseteq N/i} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup i) - f(S)]]$$

где:

- N – полный набор признаков
- S – подмножество признаков без i
- f(S) – предсказание модели с признаками S
- $f(S \cup i)$ – предсказание модели с признаками S плюс признак i
  В целом это сводится к следующему:
  Важность признака $i = p$(с признаком i)$-p$(без признака i)

Агрегирование результатов

Значения Шепли для **всех признаков суммируются для каждого наблюдения**, чтобы оценить их коллективный вклад в предсказание модели. Агрегированные данные предоставляют информацию о том, какие признаки в целом имеют наибольшее и наименьшее влияние на предсказания модели.
Часто используется среднее значение вкладов признаков по всем наблюдениям для понимания общего влияния признака в разных сценариях.
Для наглядности результаты могут быть представлены в виде диаграмм и графиков, таких как SHAP summary plots и bee swarm plots, которые показывают распределение вкладов признаков по всем наблюдениям.
SHAP Summary Plot представляет собой общий обзор влияния каждого признака на модель. Отображает как средний вклад признаков, так и распределение этих вкладов.
Bee Swarm Plot показывает распределение вкладов каждого признака для каждого наблюдения, выделяя ключевые признаки и их влияние.
Таким образом, значение Шепли вычисляет важность признака, сравнивая прогноз модели с этим признаком и прогноз модели без него. Однако, поскольку порядок, в котором появляются признаки, **может влиять на прогнозы модели**, при сравнении **мы используем различные последовательности их добавления**.
К сожалению, **перебор всех возможных комбинаций** признаков очень быстро становится **вычислительно невозможным**.
Поэтому в библиотечных методах **используется оптимизация**, которая позволяет применять значения Шепли на практике. Это достигается благодаря разработке алгоритмов, использующих преимущества внутренней структуры модели.
Например, интеграция SHAP с градиентным бустингом над деревьями решений применяет иерархию признаков в дереве для вычисления SHAP-значений.
Это позволяет библиотеке SHAP вычислять значения Шепли значительно быстрее, чем если бы мы рассчитывали прогноз модели для каждой возможной комбинации признаков.

Пример

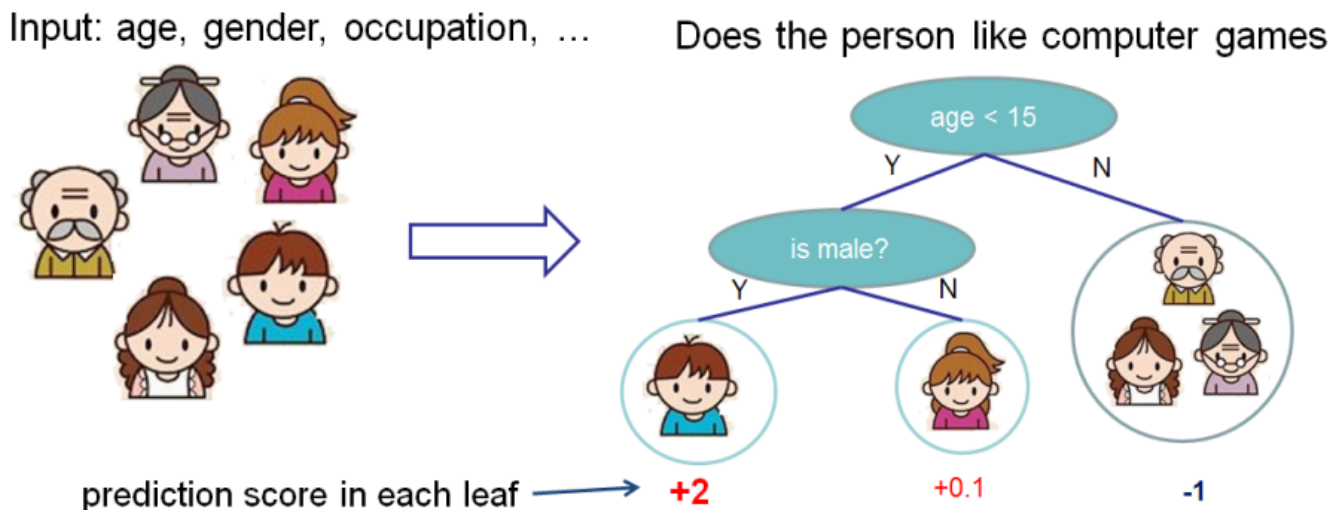

Предположим, что сначала мы видим возраст Бобби, а потом его пол.
Когда модель видит возраст Бобби, она при первом разбиении относит его к левому узлу.
Затем, поскольку у него еще нет пола, она присвоит ему среднее значение листьев ниже или $(2+0,1)/2=1,05$. Таким образом, вклад возраста составляет 1,05.
Затем, когда модель узнает, что Бобби – мужчина, она даст ему прогноз 2.
Соответственно вклад пола составляет $2-1,05=0,95$.
Таким образом, в этом случае $t_Возраст_Бобби=1,05 \quad и \quad t_Пол_Бобби=0,95$.
Замечание. Здесь показано, как работает XBoost согласно документации
А теперь представим, мы сначала видим пол Бобби, а затем его возраст.
Модель возьмет среднее по всем листьям ниже корня.
Во-первых, будет вычислено среднее значение листьев глубины 2: $(2+0,1)/2=1,05$.
Этот результат затем усредняется с листом глубины 1: $(1,05+(-1))/2=0,025$.
Таким образом, вклад пола составит $0,025$.
Затем, когда модель узнает, что ему 14, она даст ему прогноз 2. Вклад возраста составит $(2-0,025)=1,975$.
Таким образом, в этом случае $f_Возраст_Бобби=1,975 \quad и \quad f_Пол_Бобби=0,025$
Какое значение мы должны присвоить $f_Возраст_Бобби$? Если мы присвоим $f_Возраст_Бобби$ значение $1,975$, означает ли это, что мы должны присвоить $Пол_Бобби$ значение $0,025$ (так как согласно правилу 1 принципа Шепли общие коэффициенты должны равняться итоговому прогнозу модели для Бобби, в данном случае 2)?
Это далеко от идеала, поскольку такой расклад игнорирует первую последовательность, в которой $f_Пол_Бобби$ получит $0,95$, $f_Возраст_Бобби$ получит $1,05$.
Поэтому для вычисления значения Шепли мы рассматриваем оба варианта, вычисляя взвешенную сумму, чтобы найти окончательное значение.
Значит в уравнении $\phi(p)$ мы выполняем перестановки по всем возможным наборам – комбинациям признаков S (за вычетом интересующего нас признака).
Как определяются веса для каждого компонента суммы? Здесь мы учитываем, сколько

существует различных перестановок наборов, учитывая как признаки, находящиеся в наборе S (это делается с помощью операции $|S|!$), так и признаки, которые еще не были добавлены, это делается с помощью операции $(n - |S| - 1)!$).
Полученный результат нормируем на общее количество признаков. Значение Шепли для конкретного признака i (из n признаков), исходя из прогноза p (прогноза сложной модели), вычисляется по формуле:

$$[\phi_i(f) = \sum_{S \subseteq N/i} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup i) - f(S)]]$$

Пример. Возраст Бобби

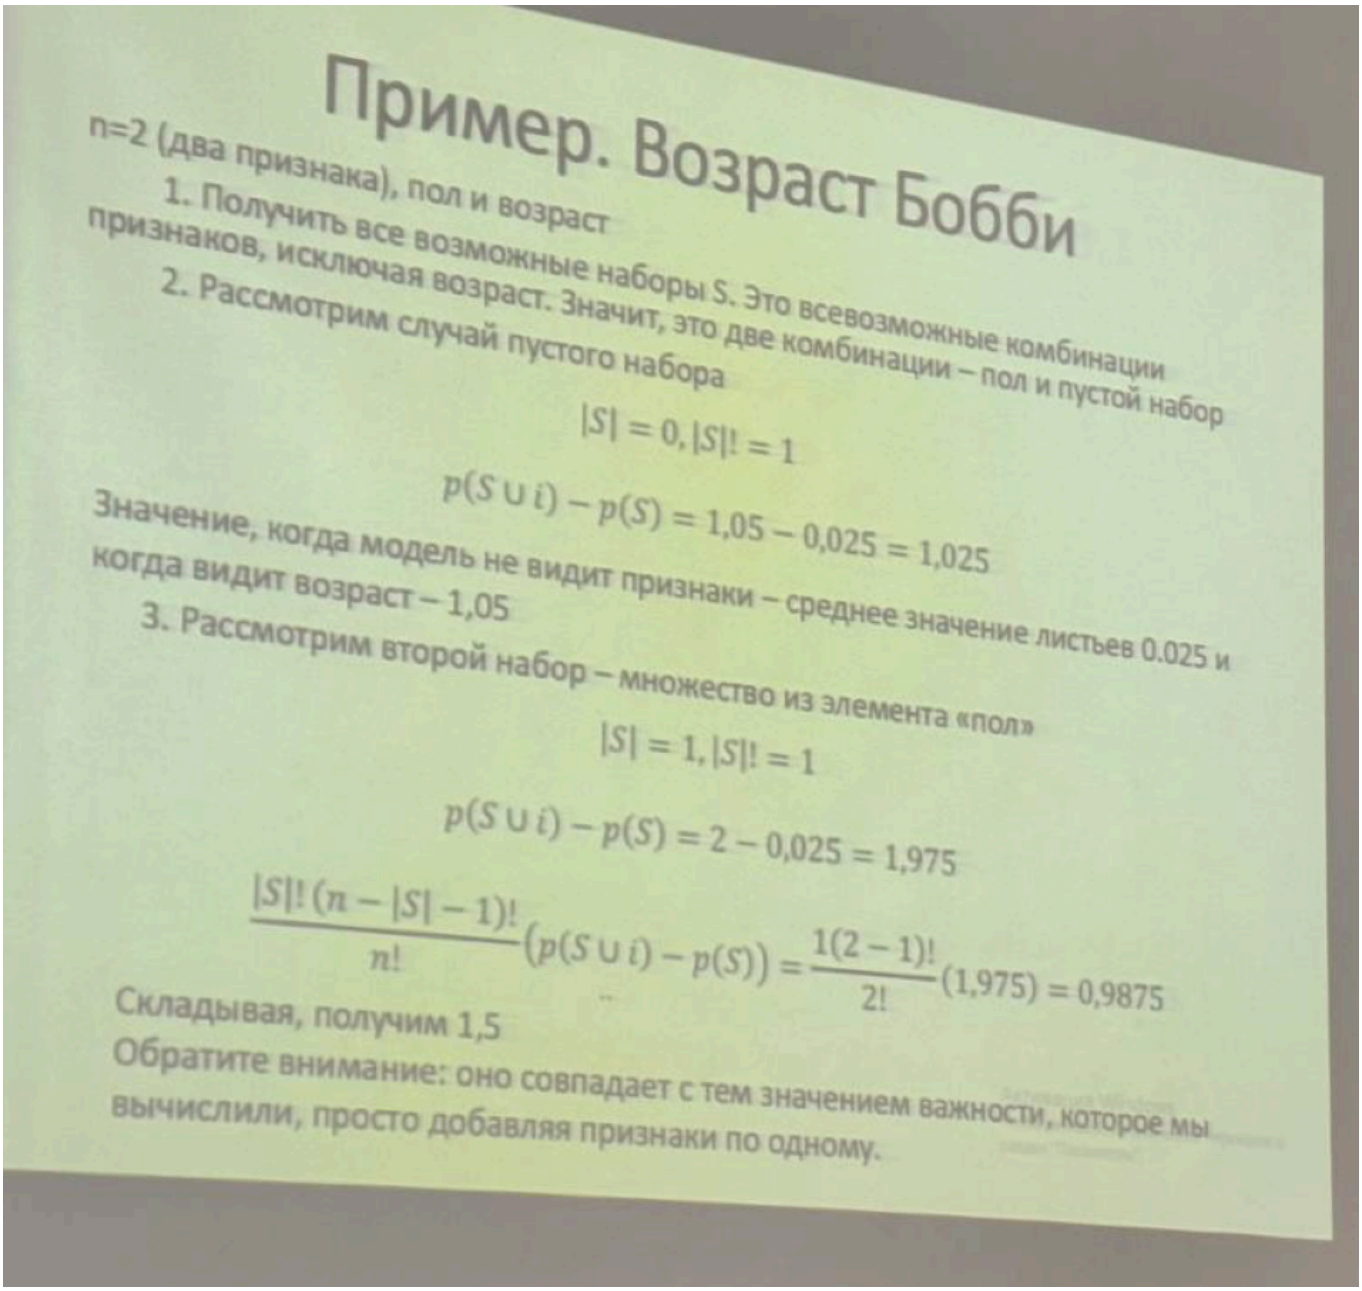

$n = 2$ (два признака), пол и возраст

1. Получить все возможные наборы S. Это всевозможные комбинации признаков, исключая возраст. Значит, это две комбинации - пол и пустой набор
2. Рассмотрим случай пустого набора

$$|S| = 0, |S|! = 1$$

$$P(S \cup t) - P(S) = 1,05 - 0,025 = 1,025$$

   Значение, когда модель не видит признаки - среднее значение листьев 0.025 и когда видит возраст - $1,05$
3. Рассмотрим второй набор - множество из элемента «пол»

$$|S| = 1, |S|! = 1$$

$$p(S \cup i) - p(S) = 2 - 0,025 = 1,975$$

$$\frac{|S|!(n - |S| - 1)!}{n!}(p(S \cup i) - p(S)) = \frac{1(2-1)!}{2!}(1,975) = 0,9875$$

Складывая, получим $1,5$
Обратите внимание: оно совпадает с тем значением важности, которое мы вычислили, просто добавляя признаки по одному.

Пример сравнения Шепли и встроенных в модели методов

Feature Importance скажет:

- 1-е место: Общая площадь (важность 0.7)
- 2-е место: Район (важность 0.2)
- 3-е место: Этаж (важность 0.1)

(Вывод: Площадь важнее всего. Ок.)

SHAP скажет (усредненно):

- Общая площадь в среднем меняет предсказание на +2 млн. руб. (от базы), причем чем больше метраж, тем сильнее в плюс.
- Район может менять предсказание и в плюс (Центр = +5 млн.), и в минус (Окраина = -1.5 млн.).
- Этаж: Первый этаж тянет цену вниз, средние этажи — вверх.

(Вывод: Мы не только знаем, что важно, но и понимаем динамику.)

Характеристика	Feature Importance (встроенная)	SHAP
Тип результата	Только глобальный рейтинг	Глобальный рейтинг + лок. объясненная
Знак влияния	Только модуль (абсолютная величина)	Есть (положительный и отрицательный вклад)
Скорость	Очень быстрая (бесплатна у деревьев)	Медленная (особенно на больших данных)
Интерпретация	Признак часто использовался	Признак изменил предсказание на X
Сложность	Низкая, понять легко	Высокая, требует понимания теории игр

LIME (Local Interpretable Model-agnostic Explanations)

Применяется чаще для локального объяснения (почему модель приняла такое решение для конкретного клиента), но на основе локальных данных можно собрать и глобальную статистику.
Шаги LIME:

1. Выборка локальных данных. Исходная точка, для которой требуется интерпретация, выбирается из набора данных. Это может быть любой пример (например, строка данных для табличных данных, изображение, текст и т.д.), для которого было сделано предсказание сложной модели.
2. Генерация синтетических вариаций путем внесения небольших изменений в исходные данные. Эти изменения могут быть реализованы различными способами, в зависимости от типа данных:
   - для табличных данных: Изменение значений признаков, добавление шума, использование техник, таких как бутстраппинг.
   - для текстовых данных: Удаление или замена слов, изменение частей текста.
   - для изображений: Изменение пикселей, применение фильтров, небольшие искажения.
     Цель состоит в том, чтобы создать набор данных, который отражает возможные вариации вокруг выбранной исходной точки.
3. Получение предсказания для каждого сгенерированного объекта
4. Вычисление веса для каждого синтетического объекта, основанного на его близости к исходной точке. Это обеспечивает, что примеры, более близкие к исходной точке, будут иметь большее влияние на обучение интерпретируемой модели.

5. Используя этот взвешенный набор данных, обучается простая интерпретируемая модель (например, линейная модель). Эта модель стремится приблизить предсказания сложной модели в локальной области, окружающей исходную точку. Коэффициенты обученной модели (для линейной модели) или другие метрики важности (например, для дерева) показывают, как каждый признак влияет на предсказание в локальной области вокруг x. Знак коэффициента указывает направление влияния (увеличивает или уменьшает предсказание), а абсолютная величина – силу влияния.

Пример

Исходный текст: «Фильм потрясающий, игра актёров великолепно, но сожет немного затянут.»
Предсказание модели: положительный (вероятность 0.85)-
Шаги LIME:

1. Выбираем этот отзыв как объект x. Признаками являются слова (или TF-IDF значения).
2. Генерируем синтетические тексты путём случайного удаления или замены немоторых слов. Например: «Фильм потрясающий, игра актёров великолепна» (удалено «но сюжет немного затянут») «Фильм ужасный, игра актёров великолепна» (замена «потрясающий» на «ужасный») и т.д.
3. Для каждого варианта получаем предсказание модели (вероятность положительного класса).
4. Вычисляем веса на основе близости: близость измеряется через долю общих слов (например, ядро на косинусном расстоянии между векторами слов). Чем больше слов совпадает с исходным текстом, тем выше вес.
5. Обучаем линейную модель (например, логистическую регрессию) на этих взвешенных данных, где признаки – наличие/отсутствие слов. Получаем козффициенты для каждого слова. Например:

   - «потрясающий»: +0.30
   - «великолепна»: +0.25
   - «затянут»: -0.15
   - «ужасный»: -0.40 (но в исходном тексте этого слова нет, поэтому его вклад нулевой)

   Интерпретация: для данного отзыва наибольший положительный вклад внесли слова «потрясающий» и «великолепна», а отрицательный – слово «затянут». Несмотря на наличие негативного слова, модель всё равно классифицирует отзыв как положительный из-за перевеса положительных слов.

Где лучше использовать LIME:

- Когда необходимо интерпретировать отдельные предсказания, например, для объяснения причин отказа в кредите.
- В случаях, когда важна скорость и вычислительная эффективность.
- При работе с небольшими наборами данных, где локальное поведение модели может существенно отличаться.

Где лучше использовать SHAP:

- Для получения глубокого и всестороннего понимания влияния. признаков как на отдельные предсказания, так и на модель в целом.
- В ситуациях, где требуется объяснение предсказаний сложных моделей, включая ансамблевые и нейронные сети.
- При анализе больших наборов данных, где важно понимать общие тенденции и взаимодействия признаков.

Замечание. Обзор методов интерпретации сложных моделей.

Если целью прогнозирования является построение максимально точных прогнозов, а не объяснение зависимости в простых терминах, то для этого используют **сложные модели** (black-box models), производящие большое число нелинейных операций над вектором признаков.
Такие модели не обладают интерпретируемостью напрямую, но можно применить разнообразные опосредованные приёмы для их анализа и объяснения их прогнозов.

1. **Изменение прогноза в зависимости от реального отклика**
   Для регрессии – график зависимости прогноза от истинного значения, для классификации – матрица ошибок.
   Полезно смотреть на те объекты, на которых модель была уверена в одном прогнозе, а верным оказался другой прогноз. Такие ошибки считаются наиболее существенными.
   В случае классификации уверенность модели можно оценить по: рейтингам классов; вероятностям классов; величине отступа.
   Если прогноз строится ансамблем, то об уверенности прогноза можно судить по числу базовых моделей, голосующих за тот или иной класс.
   Анализ таких объектов может дать подсказку, какие дополнительные свойства объектов необходимо учесть в модели, чтобы она реже ошибалась.
2. **Влияние признаков на прогнозы модели**
   Метод перестановочной важности признаков (permutation feature importance)
3. **Поведение модели на типичных и не типичных объектах**. Для отладки обученной модели полезно рассмотреть её обработку:

- типичных объектов (прототипов, prototypes);
- нетипичных объектов (критиков, criticisms);

Объекты-прототипы лежат в центрах плотно заполненных областей признакового пространства. Объекты-критики находятся, наоборот, в слабо заполненных областях пространства признаков.
Поскольку прототипы и критики ёмко описывают множество типичных и нетипичных случаев, они позволяют легко получить комплексное представление о работе модели в разных сценариях перед её внедрением.
Прототипы можно найти нак центры кластеров при кластеризации методом К-медоид. Этот метод кластеризации аналогичен методу К-средних, только центрами могут выступать лишь объекты обучающей выборки. В качестве критиков можно выбирать объекты выборки, далёкие от центров кластеров, а также друг от друга.
Существует и более продвинутая процедура выделения прототипов и критиков – MMD-critic, описанная, имеющая реализацию на python.

4. **Вклад значений отдельных признаков в прогноз. Метод Шепли.**
5. **Изменение прогноза в зависимости от изменения отдельных признаков**. Визуализировть зависимость их прогнозов от изменения отдельных входных признаков. Тем самым можно выделить признаки, оказывающие наибольшее влияние на модель, а также оценить характер этого влияния и проверить, насколько это влияние согласуется с априорными знаниями.
   График частичной зависимости (от одного признака, от двух признаков), график индивидуальных условных ожиданий, условный график, график аккумулируемых локальных эффектов)
6. **Максимально похожие объекты на заданный, для которых модель выдаёт другой прогноз**. Метод контрфактических объяснений (counterfactual explanations). Контрфактическое объяснение для $(x, f(x))$ - это такой объект x', который

   - максимально похож на x (отличается в минимальном числе признаков на минимальную величину),
   - [но в то же время обладает требуемым откликом y'.]

   Пример. Рассмотрим модель, прогнозирующую, можно ли клиенту выдать кредит или нельзя. Допустим, она выдаёт прогноз, что нельзя. Тогда можно задаться какие минимальные изменения в характеристиках клиента должны случиться, чтобы кредит ему всё-таки одобрили? Например, иметь стаж работы на год больше или получать зарплату на 10 процентов выше.
7. **Влияние отдельных объектов обучающей выборки на модель, которую мы в итоге обучим**. Прогнозы модели зависят от её параметров, которые настраиваются по обучающей выборке. Разумно поставить следующий вопрос: какие объекты обучающей выборки сильнее всего влияют на

- параметры модели,
- прогноз модели для частного объекта x,
- качество прогнозов модели для всей выборки?

Обучающие примеры, оказывающие наиболее сильное влияние, называются значимыми объектами (influential instances).

Выявление значимых объектов и силы их влияния позволяет решать следующие задачи:

- **Выявление вредных объектов**, которые приводят к смещённым прогнозам и должны быть исключены из выборки. Этими объектами могут быть:
  - объекты-выбросы, полученные, например, в результате ошибки измерения или описания нестандартных случаев, которые модель не должна обрабатывать;
  - целенаправленно занесённые ошибочные наблюдения для искажения прогнозов модели в нужную злоумышленнику сторону (data poisoning attack)
- **Верификация корректности обучающей выборки и выявление переобучения**: прогноз модели не должен определяться отдельными наблюдениями, а должен интегрировать опыт от многих обучающих примеров!
- **Приоритизация измерений для перепроверки**: вместо перепроверки корректности занесения данных от всех наблюдений перепроверим в первую очередь значимые наблюдения.
- **Обнаружение наиболее информативных объектов**, чтобы понять, какими новыми объектами дополнять обучающую выборку, чтобы расширенная обучающая выборка дала максимальное улучшение качества прогнозов (active learning).

Последнее особенно важно, когда мы обучили модель на одной выборке, а применяем к другой (с немного отличающимся распределением объектов). Используя значимые наблюдения можно анализировать несоответствие выборок и понимать, объектов какого типа не хватает при обучении модели.
Например, модель обучена предсказывать вероятность невозврата кредита на клиентах банка из одного региона, а затем применяется в другом. Если для прогнозов значимыми объектами окажутся клиенты с нестабильным источником доходов, привязанном к сезонности, то следует больше собрать данных именно по таким клиентам!
8. **Влияние отдельных частей/характеристик объекта на прогноз модели**
Например, в задаче классификации фотографий можно очень легко оценивать влияние каждого фрагмента изображения на прогноз. Для этого изображение нужно разбить на суперпиксели (superpixels), то есть группы соседних пикселей, примерно похожих по цвету и размеру, а затем поочерёдно затирать каждый суперпиксель (заполняя равномерно некоторым цветом) и смотреть, насколько изменится прогноз модели.

Дополнительные материалы

1. Interpretable Machine Learning. A Guide for Making Black Box Models Explainable. Christoph Molnar – https://christophm.github.io/interpretable-ml-book/
2. ГОСТ Р 71476-2024. Искусственный интеллект. Концепции и терминология искусственного интеллекта
3. https://arxiv.org/pdf/1901.04592
4. https://nvlpubs.nist.gov/nistpubs/ir/2021/NIST.IR.8367.pdf
5. https://github.com/AbbasPak/Feature-Importance-in-Machine-Learning
6. Важность признаков в деревьях решений – https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html
7. Примеры определения важности признаков с помощью ансамблей – https://scikit-learn.org/stable/auto_examples/ensemble/plot_forest_importances.html
8. Статья с описанием методов sklearn для определения важности признаков – https://sky.pro/wiki/analytics/sklearn-feature-importance-metod-otsenki-znachimosti-priznakov/
9. Примеры определения важности признаков на основе перестановок в sklearn – https://scikit-learn.org/stable/modules/permutation_importance.html
10. SHAP – https://medium.com/@gabrieltseng/interpreting-complex-models-with-shap-values-1c187_dbбec83, https://habr.com/ru/companies/otus/articles/779430/
11. Статья 2025 года призывает к критическому отношению метода Шепли и описывает его недостатки – https://www.sciencedirect.com/science/article/abs/pii/S0043135425004270?via%3Dihub
12. https://www.researchgate.net/publication/379306300_Feature_selection_strategies_a_comparative_analysis_of_SHAP-value_and_importance-based_methods
13. https://pmc.ncbi.nlm.nih.gov/articles/PMC12093382/table/tbl11/
14. Интерпретация моделей с помощью Lime – https://arxiv.org/pdf/1602.04938, https://rpubs.com/kachiko/lime_intro
15. LIME и SHAP – https://habr.com/ru/companies/otus/articles/779430/
16. График частичной зависимости, график индивидуальных условных ожиданий, условный график, график аккумулируемых локальных эффектов – https://scikit-learn.org/stable/modules/partial_dependence.html#tg2015, https://hastie.su.domains/ElemStatLearn/, https://arxiv.org/abs/1309.6392, https://christophm.github.io/interpretable-ml-book/ale.html, https://arxiv.org/abs/1612.08468, https://christophm.github.io/interpretable-ml-book/pdp.html, https://christophm.github.io/interpretable-ml-book/ice.html
17. Значимые объекты – https://arxiv.org/abs/2111.04683
18. Суперпиксель – https://www.researchgate.net/publication/38055641_1_A_survey_of_superpixel_methods_and_their_applicati_ons, https://scikit-image.org/docs/0.25.x/auto_examples/segmentation/plot_segmentations.html

Д/з

1. Написать пример в тетрадь кратко, но обязательно вычисления.